

Mineração de Dados Aplicada à Macroeconomia: Uma Análise do "Efeito Tesoura" Global

Luís Henrique da Silva

Pedro A. Batista

Tarsis Mikael Ventura Dumas de Lima

1. Introdução

Este relatório documenta o código desenvolvido no notebook `main.ipynb` para a disciplina de Mineração de Dados. O objetivo é analisar o comportamento de países frente a três indicadores do Banco Mundial entre 2010 e 2023 e extrair insights sobre a relação entre dívida pública e gastos sociais.

2. Justificativa


O trabalho busca fundamentar a hipótese de que um país pode ser financeiramente pressionado pelo "efeito tesoura": quando o pagamento de dívida consome uma parcela alta da receita, a capacidade de investimento em saúde e educação fica comprometida. Essa análise é relevante para demonstrar um problema estrutural que impacta o desenvolvimento social.

3. Revisão da Literatura

O conceito de "efeito tesoura" é discutido na literatura econômica como a deterioração da capacidade fiscal de um país quando despesas com juros crescentes reduzem os recursos disponíveis para políticas sociais. Em contextos de alta dívida pública, a literatura aponta que o aumento dos encargos financeiros tende a apertar o orçamento da saúde e da educação.

Na literatura de Mineração de Dados, o algoritmo K-Means é amplamente utilizado para segmentação não supervisionada, permitindo agrupar observações semelhantes em clusters e identificar padrões em dados macroeconômicos. Estudos de políticas públicas usam K-Means para separar perfis de países por indicadores fiscais e sociais.

Já o Apriori é uma técnica clássica de mineração de regras de associação, usada para descobrir relações frequentes entre atributos discretos. Em análises de dados socioeconômicos, Apriori ajuda a revelar associações como "dívida alta" e "gasto social baixo", fornecendo suporte empírico a hipóteses de políticas.



4. Base de Dados

4.1. Pré-processamento e Engenharia de Atributos

A base de dados consolidada para os algoritmos de Inteligência Artificial abrangeu o histórico médio de 14 anos (2010 a 2023). Após o tratamento de dados e remoção de registros nulos (com o comando `dropna`), a matriz final resultou em 164 países e blocos regionais válidos, contendo 4 atributos principais por registro: Código do País, Nome do País, Custo Estrutural da Dívida (% da receita) e Gasto Social Consolidado (% do PIB).

Os dados foram extraídos do portal oficial do Banco Mundial (World Bank Open Data). Foram utilizados três arquivos CSV do World Bank:

- ``API_GC.XPN.INTP.RV.ZS_DS2_en_csv_v2_10000.csv`` - Pagamento total da dívida (% da receita total)
- ``API_SE.XPD.TOTL.GD.ZS_DS2_en_csv_v2_115540.csv`` - Gastos totais com educação (% do PIB)
- ``API_SH.XPD.GHED.GD.ZS_DS2_en_csv_v2_115647.csv`` - Gastos totais com saúde (% do PIB)

Cada arquivo contém 266 registros e 71 colunas, incluindo os atributos:

- ``Country Name``
- ``Country Code``
- ``Indicator Name``
- ``Indicator Code``
- colunas anuais de ``1960`` a ``2025``

Para esta análise, considerou-se o período de 2010 a 2023, pois corresponde aos anos em que o Brasil possui dados consistentes sobre os gastos. O notebook realiza a média histórica dos valores disponíveis nesse intervalo para cada país e elimina as nações com dados incompletos nos indicadores selecionados.

5. Metodologia


5.1 Preparação dos Dados

- Carregamento dos CSVs com ``pandas.read_csv(..., skiprows=4)`` para ignorar metadados de cabeçalho.
- Cálculo da média de cada indicador por país no período 2010-2023.
- Consolidação em um único DataFrame com as colunas:
 - ``Educacao_PIB``
 - ``Saude_PIB``
 - ``Pagamento_Total_Divida``

- Criação do indicador composto:
 - ``Gasto_Social = Educacao_PIB + Saude_PIB``
- Exclusão de países com dados incompletos para esses indicadores.


5.2 Validação do Número de Clusters

- Foi calculado o coeficiente de silhueta para ``K`` variando de 2 a 7.
- O gráfico de silhueta mostra que ``K=3`` é a escolha mais adequada para separar os padrões entre dívida e gasto social.
- Essa validação justifica matematicamente a configuração utilizada no K-Means.



5.3 Agrupamento com K-Means

- Foram selecionadas as variáveis ``Pagamento_Total_Divida`` e ``Gasto_Social`` para a clusterização.
- Os dados foram padronizados com ``StandardScaler()`` para evitar influência de escala diferente entre as features.
- O algoritmo ``KMeans`` foi executado com ``n_clusters=3`` e ``random_state=42``.
- O modelo classificou os países em três grupos:
 - Grupo 1: ``Eficiência Social``
 - Grupo 2: ``Alerta / Transição``
 - Grupo 3: ``Asfixiados por Dívida``



5.4 Mineração de Regras com Apriori

- O conjunto de dados consolidado foi convertido em categorias binárias usando `pd.qcut`:
 - `Faixa_Dívida`: `Dívida_Baixa` ou `Dívida_Alta`
 - `Faixa_Social`: `Social_Baixo` ou `Social_Alto`
- Foi criada uma matriz transacional com `pd.get_dummies` e convertida para booleanos.
- O algoritmo `apriori` da biblioteca `mlxtend` foi aplicado com suporte mínimo de 15%.
- Em seguida, foram geradas regras de associação com `association_rules(..., metric='confidence', min_threshold=0.55)`.
- O resultado evidencia relações como `Dívida_Alta → Social_Baixo` e outras regras fortes do "efeito tesoura".

```
=====
AS REGRAS MAIS FORTES DO EFEITO TESOURA (Confiança > 55%)
=====
```

```
REGRA: SE [Dívida_Baixa] ---> ENTÃO [Social_Alto]
```

- Confiança : 63.8% de certeza.
- Suporte : 31.9% dos países do mundo.
- Lift : 1.28x (Força da correlação)

```
REGRA: SE [Social_Alto] ---> ENTÃO [Dívida_Baixa]
```

- Confiança : 63.8% de certeza.
- Suporte : 31.9% dos países do mundo.
- Lift : 1.28x (Força da correlação)

```
REGRA: SE [Dívida_Alta] ---> ENTÃO [Social_Baixo]
```

- Confiança : 63.8% de certeza.
- Suporte : 31.9% dos países do mundo.
- Lift : 1.28x (Força da correlação)

```
REGRA: SE [Social_Baixo] ---> ENTÃO [Dívida_Alta]
```

- Confiança : 63.8% de certeza.
- Suporte : 31.9% dos países do mundo.
- Lift : 1.28x (Força da correlação)

```
-----
DIAGNÓSTICO DO BRASIL: Anomalia detectada (Dívida_Alta e Social_Alto).
=====
```

6. Resultados

6.1 Clusterização e Interpretação

O modelo agrupou os países em três perfis distintos:

- Países com menor dívida e maior gasto social, associados a maior eficiência ou investimento social.
- Países de transição, que apresentam valores intermediários e merecem atenção.
- Países asfixiados por dívida, com alta carga de juros e menor capacidade de gasto social.

No relatório de código, o Brasil aparece como um caso importante de análise. O notebook destaca o Brasil nos gráficos e na seleção de países de referência para comparação.

6.2 Validação do K-Means

O coeficiente de silhueta foi usado para demonstrar que `K=3` é uma escolha estável e justificada. Esse gráfico é um dos principais resultados de validação, porque mostra que a separação em três grupos tem boa coesão interna e separação entre clusters.

6.3 Mineração de Regras

As regras mais relevantes encontradas pelo Apriori mostram estruturas de associação entre dívida e gasto social. O relatório do código coloca em evidência regras com confiança acima de 55%, o que ajuda a traduzir os dados em conclusões de negócio claras.

7. Discussão

- O trabalho mostra como a dívida pública afeta o espaço fiscal disponível para saúde e educação.
- A análise é compatível com a narrativa do "efeito tesoura": juros altos limitam investimentos sociais.
- O uso de clusterização revela blocos de países com comportamento semelhante, incluindo um grupo de maior risco.
- A mineração de regras reforça a relação entre dívida alta e gasto social reduzido.

Pergunta-chave para a banca: se pagamos muito juro, o que acontece com a saúde e a educação?

8. Conclusão

O código desenvolvido entrega uma análise estruturada que atende às exigências do projeto: base de dados, pré-processamento, agrupamento de dados, validação de clusters e regras de associação.

O principal insight é que existe um padrão global em que dívidas maiores tendem a pressionar os gastos sociais, evidenciando um problema estrutural relevante para políticas públicas.

Essa conclusão é consistente com debates atuais sobre o Brasil, em que notícias econômicas destacam como a dívida pública e os encargos financeiros pressionam o orçamento da saúde e da educação.

9. Anexos

9.1 Observações Técnicas

- O notebook usado é `main.ipynb`.
- As bibliotecas empregadas incluem: `pandas`, `matplotlib`, `seaborn`, `sklearn`, `scipy`, `adjustText`, `mlxtend`.
- O processo foi realizado de forma reproduzível com os arquivos CSV listados na seção 4.

10. Referências Bibliográficas

- BANCO MUNDIAL (World Bank). World Development Indicators: Government expenditure on education, total (% of GDP), Domestic general government health expenditure (% of GDP), and Interest payments (% of revenue). Washington, D.C.: World Bank Group, 2026. Disponível em: <<https://databank.worldbank.org/>>.
- PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, v. 12, p. 2825-2830, 2011. Disponível em: <<https://scikit-learn.org/>>.
- RASCHKA, Sebastian. MLxtend: Providing machine learning and data science utilities and extensions to Python's scientific computing stack. The Journal of Open Source Software, v. 3, n. 24, p. 638, 2018. Disponível em: <<https://rasbt.github.io/mlxtend/>>.
- VALOR ECONÔMICO. Custo da dívida pública e o espaço para investimentos em saúde e educação no Brasil. São Paulo: Globo e Associados, 2026. Disponível em: <<https://valor.globo.com/>>.